

Treball Final de Màster

Estudi: Màster en Ciència de Dades

Títol: Control híbrid basat en Aprenentatge per Reforç i Control Predictiu per a l'optimització segura de sistemes d'emmagatzematge amb bateries

Document: Memòria

Alumne: David Bruguera Tornés

Tutor: Andrés El-Fakdi Sencianes
Departament: Enginyeria Elèctrica, Electrònica i Automàtica
Àrea: Enginyeria Elèctrica

Convocatòria (mes/any): Juny 2026

TREBALL FINAL DE MÀSTER

**Control híbrid basat en
Aprenentatge per Reforç i Control
Predictiu per a l'optimització
segura de sistemes
d'emmagatzematge amb bateries**

Autor:

David BRUGUERA TORNÉS

Juny 2026

Màster en Ciència de Dades

Tutor:

Andrés EL-FAKDI SENCIANES

Resum

La creixent penetració de fonts d'energia renovable distribuïdes introdueix una elevada volatilitat en la generació i en els preus de l'electricitat. En aquest context, els sistemes d'emmagatzematge d'energia en bateria (*Battery Energy Storage Systems*, BESS) són elements crítics per aportar flexibilitat i estabilitat. No obstant això, la seva gestió òptima és complexa: els mètodes clàssics com el Control Predictiu basat en Model (MPC) gestionen bé les restriccions físiques però depenen de la precisió del model, mentre que l'Aprenentatge per Reforç (RL) s'adapta a entorns estocàstics però no garanteix per si sol la seguretat operativa.

Aquest TFM aborda el problema del control segur i econòmicament eficient d'un BESS de 50 kWh per a una comunitat energètica situada a Cornellà (Barcelona), composta per una escola i 20 habitatges amb generació fotovoltaica compartida. La principal contribució és el disseny, la implementació i la validació d'una **arquitectura de control híbrida** de tipus *RL-guided MPC*, en què un agent d'Aprenentatge per Reforç (PPO, *Proximal Policy Optimization*) proposa un SoC objectiu i un controlador MPC el segueix de manera segura respectant les restriccions físiques de la bateria.

L'arquitectura proposada s'avalua sobre dades simulades generades pel simulador de la comunitat energètica desenvolupat per Martí Cabarrocas I Sánchez en el seu Treball de Fi de Grau. La comparativa inclou quatre estratègies de control: la inacció induïda per l'MPC greedy d'un sol pas MPC(H=1), l'MPC amb horitzó de 60 minuts MPC(H=60), l'agent RL en solitari i l'arquitectura híbrida MPC+RL. Les mètriques d'avaluació inclouen el benefici econòmic acumulat, el cost de degradació estimat i el nombre de cicles de bateria induïts.

Els resultats sobre el conjunt de test complet (1.460 dies, 2.102.400 minuts de simulació) estableixen el rànquing definitiu: MPC+RL (−87.142 €) > RL (−94.035 €) > MPC(H=60) (−97.502 €) > MPC(H=1) (−97.827 €). L'arquitectura híbrida MPC+RL supera la inacció total del MPC greedy en **10.684 € (10,9%)**, equivalent a **7,32 €/dia d'estalvi**. L'agent RL en solitari supera el MPC amb horitzó de 60 minuts en 3.468 €, amb una *policy* de ciclatge quasi-perfectament simètrica (44.583,0 vs 44.580,6 kWh en 1.460 dies). El *tracker* MPC de l'arquitectura híbrida garanteix la simetria exacta de la càrrega/descàrrega (97.526,5 kWh en ambdues direccions) i un SoC mitjà de 0,705, demostrant que la combinació de RL i MPC permet obtenir *policies* econòmicament eficients i operativament estables.

Índex

1	Introducció	1
1.1	Context i motivació	1
1.2	Problema considerat	1
1.3	Treballs relacionats	2
1.4	Objectius	2
1.5	Contribucions	3
1.6	Resultats destacats	4
1.7	Estructura de la memòria	4
2	Estat de l'art	5
2.1	Comunitats energètiques i BESS	5
2.2	Control Predictiu basat en Model (MPC)	5
2.3	Aprenentatge per reforç per al control de BESS	6
2.4	Optimització amb CVXPY	8
2.5	Stable-Baselines3 i Gymnasium	8
3	Preliminars	11
3.1	Domini: la comunitat energètica de Cornellà	11
3.2	Notació i definicions	11
3.3	Dinàmica de la bateria	12
3.4	Funció de benefici econòmic	12
3.5	Model de preus i degradació	13
3.6	El Procés de Decisió de Markov (MDP)	14
3.6.1	Cicle estat–acció–estat–recompensa	14
3.6.2	Diagrama agent–entorn	15
3.7	Aprenentatge per reforç: PPO	16
3.8	Control Predictiu basat en Model (MPC)	16
4	Planificació i Metodologia	17
4.1	Metodologia de desenvolupament	17
4.2	Estructura del codi	17
4.3	Planificació temporal	18
4.4	Costos del projecte	18

5	Contribució Metodològica	21
5.1	Arquitectura del sistema	21
5.2	Entorn de simulació RL (BessEnv)	21
5.2.1	Espai d'observació	21
5.2.2	Espai d'acció	22
5.2.3	Funció de recompensa	22
5.2.4	Funció de recompensa de l'entorn MPC+RL	23
5.3	Controlador MPC greedy	23
5.4	Entrenament de l'agent PPO	24
5.4.1	Divisió entrenament / validació (80 % / 20 %)	24
5.4.2	Implementació real de PPO al projecte	25
5.5	Decisions de disseny crítiques	26
6	Resultats	27
6.1	Controladors avaluats	27
6.2	Configuració experimental	27
6.3	Resultats sobre el conjunt de test complet (1.460 dies)	28
6.4	Evolució de l'entrenament	28
6.5	Anàlisi del comportament diari	29
6.6	Estudi d'ablació: funció d'activació i GAE- λ	29
6.7	Discussió	31
7	Conclusions i treball futur	35
7.1	Resum de les contribucions	35
7.2	Avaluació crítica dels resultats	35
7.3	Consideracions ètiques i legals	36
7.4	Treball futur	36
	Bibliografia	39

Índex de figures

3.1	Cicle fonamental de l'MDP: l'agent en l'estat s_t selecciona una acció a_t seguint la <i>policy</i> π_θ ; l'entorn transita al nou estat s_{t+1} (distribució $\mathcal{T}$) i genera la recompensa r_{t+1} (funció $\mathcal{R}$). La fletxa discontinua representa el pas temporal que reinicia el cicle.	15
3.2	Diagrama canònic agent-entorn en RL aplicat al control del BESS. L'agent PPO genera l'acció de control $a_t \in [-1, 1]$ (fracció de potència màxima); l'entorn (BessEnv) executa la dinàmica de la bateria, calcula la recompensa econòmica r_{t+1} i retorna el nou estat s_{t+1} . La caixa discontinua recorda que les decisions actuals poden tenir efectes econòmics visibles en passos posteriors (<i>delayed reward</i>).	15
5.1	Arquitectura del sistema. El simulador genera CSVs diaris; l'agent PPO s'entrena sobre el conjunt d'entrenament i, en inferència, el controlador RL pur proposa una acció directa a_t , mentre que el controlador MPC+RL proposa un SoC objectiu cada 60 minuts que un <i>tracker</i> MPC segueix minut a minut.	21
6.1	Corbes d'aprenentatge de l'agent PPO i del controlador MPC+RL durant l'entrenament. El panell superior mostra la recompensa mitjana per episodi, i el panell inferior l' <i>explained variance</i> del crític, utilitzada com a indicador de convergència.	29
6.2	Comportament d'un dia típic d'estiu (dia 93 del conjunt de test). <i>Dalt</i> : evolució del SoC de la bateria per als quatre controladors al llarg de les 24 hores. <i>Centre</i> : potència de bateria (positiu = càrrega; negatiu = descàrrega). <i>Baix</i> : generació fotovoltaica i demanda total de la comunitat (kW).	30
6.3	Estudi d'ablació sobre el model MPC+RL (500.000 timesteps, macro-pas 60 min). <i>Esquerra</i> : efecte de la funció d'activació amb $\lambda = 0,95$. <i>Dreta</i> : efecte del paràmetre GAE- λ amb activació ReLU. La recompensa representa el guany marginal respecte a l'escenari sense bateria. La línia gruixuda correspon a la mitjana mòbil (finestra de 7 episodis) i la banda ombrejada mostra l'interval de confiança del 95 % ($\bar{x} \pm 1,96 \sigma$) de la variabilitat observada durant l'entrenament.	31

Índex de taules

4.1	Planificació temporal prevista vs real del projecte.	18
5.1	Variables d'observació i constants de normalització.	22
5.2	Hiperparàmetres de l'entrenament PPO.	25
6.1	Resultats comparatius sobre el conjunt de test complet (1.460 dies, 2.102.400 passos de temps).	28
6.2	Resultats de l'estudi d'ablació sobre el model MPC+RL (500K timesteps, macro-pas 60 min). La recompensa és el guany marginal respecte a l'escenari sense bateria; valors més positius indiquen millor rendiment.	32
6.3	Estalvi net sobre el conjunt de test complet (1.460 dies) respecte al MPC(H=1).	33

CAPÍTOL 1

Introducció

1.1 Context i motivació

La transició cap a un model energètic sostenible ha incrementat la penetració de fonts renovables distribuïdes, la qual cosa introdueix una elevada volatilitat en la generació i en els preus de l'electricitat. En aquest escenari, els sistemes d'emmagatzematge amb bateries (*Battery Energy Storage Systems*, BESS) són elements crítics per aportar flexibilitat i estabilitat a la xarxa elèctrica. Un BESS ben gestionat pot absorbir els excedents de generació fotovoltaica durant les hores de màxima irradiació i alliberar-los durant els períodes de demanda elevada o preu alt; a més, també pot carregar-se des de la xarxa quan el preu és baix per consumir o descarregar aquesta energia més endavant, quan el preu és més alt, reduint la factura energètica i augmentant l'autosuficiència.

No obstant això, la gestió òptima d'un BESS no és trivial. Dues grans famílies de mètodes s'han consolidat a la literatura:

- **Control Predictiu basat en Model (MPC):** gestiona bé les restriccions físiques i proporciona garanties de seguretat, però depèn de la precisió del model del sistema i de les previsions de generació i demanda. En presència d'incertesa estocàstica, el seu rendiment es degrada.
- **Aprenentatge per Reforç (RL):** s'adapta bé a entorns complexos i estocàstics sense necessitat d'un model explícit, però en la seva forma estàndard no garanteix inherentment el compliment de restriccions físiques, la qual cosa pot comprometer la seguretat operativa i la vida útil dels equips.

Aquest TFM neix de la necessitat d'explorar **arquitectures híbrides** que combinin el millor d'ambdós mons: la capacitat d'adaptació del RL i la robustesa operativa del MPC.

1.2 Problema considerat

En el cas concret d'aquest treball, la comunitat energètica objecte d'estudi es troba a Cornellà de Llobregat (Barcelona) i està composta per una escola de

primària i 20 habitatges unifamiliars connectats a la mateixa xarxa de distribució. La instal·lació disposa d'una coberta de panells fotovoltaics compartits i d'un BESS amb una capacitat útil de 50 kWh i una potència màxima d'inversor de 50 kW.

El problema de control consisteix a decidir, a cada instant de temps (amb una granularitat d'1 minut), quanta potència carregar o descarregar del BESS per tal de maximitzar el benefici econòmic net de la comunitat al llarg del dia. El benefici econòmic reportat es defineix com l'estalvi en la factura elèctrica (energia autoproduïda consumida directament, sense passar per la xarxa) més els ingressos per venda d'excedents a la xarxa, menys el cost de degradació de la bateria. Les restriccions tècniques (SoC i potència) es tracten principalment com a restriccions dures, i en l'entrenament RL s'afegeix una penalització quan l'acció proposta excedeix aquests límits.

Les principals dificultats tècniques que presenta el problema són:

- **Variabilitat dels preus:** els preus de mercat PVPC varien hora a hora, de manera que la decisió de quan carregar i quan descarregar té un impacte econòmic significatiu.
- **Incertesa en la generació i la demanda:** la producció solar i el consum dels membres de la comunitat no són perfectament predictibles.
- **Restriccions tècniques de la bateria:** l'estat de càrrega (*State of Charge*, SoC) ha de mantenir-se entre uns límits mínims i màxims per preservar la vida útil de la bateria.
- **Horitzó temporal llarg:** l'estratègia òptima requereix raonament a diverses hores vista (p.ex., carregar durant la nit, quan l'electricitat és barata, per descarregar al migdia o a la tarda).

1.3 Treballs relacionats

El control de BESS en microxarxes i comunitats energètiques és un tema àmpliament estudiat a la literatura. Les dues famílies d'enfocaments predominants són els mètodes basats en optimització (MPC i programació dinàmica) i els basats en aprenentatge automàtic (sobretot RL). En la Secció 2 es fa una revisió més detallada de l'estat de l'art.

1.4 Objectius

L'objectiu principal d'aquest TFM és **dissenyar, implementar i validar una estratègia de control híbrida que integri un agent d'Aprenentatge per Reforç**

amb un controlador MPC de seguiment per a l'operació segura i econòmicament eficient d'un BESS.

Els objectius específics són:

1. **Entorn de simulació:** desenvolupar un entorn de simulació que integri un model de bateria i perfils reals de mercat elèctric, generació fotovoltaica i demanda, aprofitant el simulador de comunitat energètica de Martí Cabarrocas I Sánchez.
2. **Agent RL:** implementar un agent RL (PPO) capaç d'aprendre una *policy* de càrrega i descàrrega que maximitzi l'estalvi econòmic.
3. **Capa de seguretat:** integrar un *tracker* MPC que segueixi un SoC objectiu proposat per l'agent RL i garanteixi el compliment de les restriccions físiques i tècniques (límits de SoC, potència màxima d'inversor).
4. **Avaluació comparativa:** comparar el rendiment de l'arquitectura híbrida respecte a un controlador MPC greedy com a línia base, en termes de benefici econòmic acumulat, taxa de violació de restriccions i degradació estimada de la bateria.

1.5 Contribucions

Les principals contribucions d'aquest TFM són:

1. **Disseny i implementació de l'arquitectura híbrida RL + MPC:** l'agent PPO proposa un SoC objectiu cada 60 minuts, i un *tracker* MPC calcula les accions minut a minut per seguir-lo de manera segura.
2. **Entorn de simulació RL** (Gymnasium/BessEnv) integrat amb el simulador de la comunitat energètica de Martí Cabarrocas I Sánchez, amb preus PVPC variables i normalització d'observacions.
3. **Implementació d'un controlador MPC greedy** basat en CVXPY i el solver CLARABEL com a línia base interpretable.
4. **Ajust rigorós de la funció de recompensa:** identificació i correcció de problemes d'aprenentatge (*policy* d'inacció per penalització excessiva, preus plans, normalització inadequada).
5. **Avaluació comparativa** sobre un conjunt de test representatiu, incloent mètriques econòmiques, de seguretat i de degradació.

1.6 Resultats destacats

Sobre el conjunt de test complet (1.460 dies), l'arquitectura híbrida MPC+RL aconsegueix un benefici net de -87.142 €, reduint la pèrdua econòmica en **10.684 € (10,9%)** respecte al MPC greedy inactiu i en **6.892 €** respecte al RL en solitari. L'agent RL, malgrat no tenir previsions explícites de generació i demanda, supera el MPC amb horitzó de 60 minuts en 3.468 €, amb una *policy* de ciclatge quasi-perfectament simètrica ($44.583,0$ vs $44.580,6$ kWh). Es detallen en el Capítol 6.

1.7 Estructura de la memòria

La resta d'aquest document s'organitza de la manera següent. El Capítol 2 revisa la literatura relacionada. El Capítol 3 presenta els preliminars: descripció del domini, notació i mètodes de base. El Capítol 4 descriu la planificació i metodologia del projecte. El Capítol 5 detalla la contribució metodològica. El Capítol 6 presenta i analitza els resultats. Finalment, el Capítol 7 recull les conclusions i el treball futur.

CAPÍTOL 2

Estat de l'art

2.1 Comunitats energètiques i BESS

Les comunitats energètiques locals (*Local Energy Communities*, LEC) han estat objecte d'una atenció creixent tant des del punt de vista regulatori com tècnic. La Directiva Europea 2018/2001 (RED II) defineix el marc legal que permet als ciutadans compartir energia generada localment, i la seva transposició al reglament espanyol (Reial Decret 244/2019) ha facilitat el desplegament de comunitats d'autoconsum compartit a l'Estat.

Des del punt de vista tècnic, la gestió del BESS en una LEC pot formular-se com un problema d'optimització estocàstica on l'objectiu és maximitzar el valor econòmic al llarg d'un horitzó temporal donat, subjecte a restriccions físiques de la bateria i de la xarxa [Parra 2017, Koirala 2016].

2.2 Control Predictiu basat en Model (MPC)

El MPC és l'enfocament clàssic per al control òptim de sistemes dinàmics amb restriccions [Camacho 2007, Garcia 1989]. En la seva forma estàndard, resol en cada pas de temps un problema d'optimització sobre un horitzó futur, considerant les previsions de generació i demanda com a paràmetres coneguts. Oldewurtel et al. [Oldewurtel 2012] demostren que el MPC pot reduir significativament el consum energètic en edificis quan es combina amb previsions meteorològiques, però la seva eficàcia es degrada quan les previsions són incertes. Morstyn et al. [Morstyn 2018] revisen estratègies de control per a microxarxes amb BESS distribuïts i conclouen que el MPC ofereix les millors garanties en entorns amb models precisos, però presenta limitacions en escenaris d'alta variabilitat. Una variant simplificada és el *greedy MPC d'un sol pas*, que resol el problema únicament per al pas de temps actual sense considerar l'horitzó futur; malgrat la seva senzillesa, es fa servir habitualment com a línia base en la literatura.

Des del punt de vista dels components del sistema elèctric que ha de modelar, un controlador MPC per a BESS incorpora:

- **Bateria (BESS):** dinàmica de l'estat de càrrega (equació (3.1)), límits operatius de SoC i model de degradació per ciclatge.

- **Inversor:** límit de potència màxima $P_{\max}$. En la implementació d'aquest TFM s'assumeix eficiència unitària ($\eta_c = \eta_d = 1$), de manera que no es modelen pèrdues AC/DC de forma explícita.
- **Connexió a la xarxa:** preus de compra i venda (p_t^+ , p_t^-) i restriccions d'importació/exportació.
- **Fonts renovables:** previsions de generació fotovoltaica (deterministes si es disposa de predicció meteorològica, estocàstiques en cas d'incertesa).

L'horitzó de predicció H és el paràmetre de disseny més crític: un horitzó curt (p.ex., $H = 1$, el *greedy MPC*) és reactiu i computacionalment trivial, però no pot anticipar períodes favorables; un horitzó llarg (p.ex., $H = 1440$ per a un dia sencer) permet planificació global però requereix previsions precises i incrementa quadràticament la càrrega computacional. En aquest TFM s'avaluen $H = 1$ i $H = 60$ minuts com a casos extrem i moderat, respectivament.

2.3 Aprenentatge per reforç per al control de BESS

L'aprenentatge per reforç (RL) ofereix una alternativa atractiva al MPC quan la dinàmica del sistema és incerta o quan el problema d'optimització és massa complex per resoldre'l en temps real. L'agent aprèn una *policy* de control a través de la interacció amb un entorn simulat, sense necessitat de conèixer explícitament el model del sistema.

Perera i Kamalaruban [Perera 2021] proporcionen una revisió exhaustiva de l'aplicació del RL a sistemes d'energia, identificant quatre famílies d'algoritmes principals i els seus àmbits d'aplicació. Vazquez-Canteli i Nagy [Vazquez-Canteli 2019] revisen específicament algoritmes RL per a la resposta a la demanda, destacant la importància del disseny de la funció de recompensa. A continuació es resumeixen les contribucions clau per a cadascuna de les famílies d'algoritmes:

- **DQN i variants:** Mnih et al. [Mnih 2015] van introduir el *Deep Q-Network* (DQN), que combina Q-learning amb xarxes neuronals profundes. En el context energètic, DQN s'ha aplicat discretitzant l'espai d'accions de càrrega/descàrrega, però la discretització introdueix imprecisió en la gestió de potències contínues.
- **DDPG i TD3:** Lillicrap et al. [Lillicrap 2016] van proposar el *Deep Deterministic Policy Gradient* (DDPG) per a espais d'accions continus, i Fujimoto et al. [Fujimoto 2018] el van millorar amb TD3, reduint la sobreestimació del valor-Q. Ambdós algoritmes s'adapten millor que DQN al control de potència contínua en BESS.

- **PPO:** Nakabi i Toivanen [Nakabi 2021] apliquen PPO a la gestió energètica d'una microxarxa amb demanda flexible i obtenen estratègies de control robustes que superen regles heurístiques i MPC en presència d'incertesa. Schulman et al. [Schulman 2017] van demostrar que el mecanisme de restricció de PPO garanteix actualitzacions estables de la *policy*, especialment valuós en entorns amb recompenses esparses.
- **SAC:** Haarnoja et al. [Haarnoja 2018] van proposar el *Soft Actor-Critic* (SAC), que maximitza simultàniament el retorn esperat i l'entropia de la *policy*, millorant l'exploració. SAC és especialment adequat per a tasques de control continu amb dinàmiques complexes.

Des del punt de vista dels components i les eines de l'Aprenentatge per Reforç, la literatura distingeix tres famílies principals d'algoritmes [Sutton 2018]:

- **Mètodes basats en funció de valor** (*value-based*): estimen la funció $Q^*(s, a)$ directament i deriven una *policy* greedy. DQN [Mnih 2015] és el paradigma principal d'aquesta família. L'inconvenient per al control del BESS és que requereixen discretitzar l'espai d'accions, introduint imprecisió en la gestió de potències contínues.
- **Mètodes de gradient de *policy*** (*policy gradient*): optimitzen directament $\pi_\theta(a | s)$ per gradient ascendent. REINFORCE [Sutton 2018] és el cas bàsic, però pateix alta variança en l'estimació del gradient, especialment en episodis llargs com els d'un dia sencer de 1440 passos.
- **Mètodes actor-crític** (*actor-critic*): combinen un actor (*policy* π_θ) i un crític (funció de valor V_ϕ) per reduir la variança sense introduir biaix significatiu. L'avantatge $\hat{A}_t = Q(s_t, a_t) - V(s_t)$ guia les actualitzacions de la *policy*. PPO, SAC i TD3 pertanyen a aquesta família i són els més emprats en control d'energia.

Un component clau dels algoritmes actor-crític moderns és l'estimació d'avantatge generalitzat (GAE), que introdueix un paràmetre $\lambda \in [0, 1]$ per controlar el compromís biaix-variança:

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \cdot \lambda)^l \cdot \delta_{t+l}, \quad \delta_t = r_t + (\gamma \cdot V_\phi(s_{t+1})) - V_\phi(s_t) \quad (2.1)$$

on $\lambda = 0$ recupera l'error TD d'un sol pas (alta biaix, baixa variança) i $\lambda = 1$ recupera el retorn Monte Carlo complet (baixa biaix, alta variança). En aquest TFM s'utilitza $\lambda = 0.98$ per a l'agent RL pur i $\lambda = 0.95$ per a l'agent MPC+RL.

Per facilitar la lectura de l'Equació (2.1):

- $\hat{A}_t$: avantatge estimat al pas t (quant millor ha estat l'acció feta respecte al que esperava el crític).
- γ : factor de descompte de futur.
- λ : paràmetre de GAE que regula el compromís biaix-variança.
- δ_t : error TD del crític al pas t .
- $V_\phi(s_t)$: valor estimat de l'estat s_t per la xarxa crítica (paràmetres ϕ).
- r_t : recompensa immediata observada en aquell pas.
- l : índex que recorre errors TD futurs ponderats per $(\gamma\lambda)^l$.

En paraules: GAE construeix l'avantatge combinant l'error actual i errors futurs amb pesos decreixents. Això redueix la variança respecte a Monte Carlo pur, però sense quedar-se en una aproximació massa local de tipus un-sol-pas.

En la pràctica del TFM, Stable-Baselines3 calcula aquesta suma sobre trajectòries finites (no infinites) i la trunca al final d'episodi. Els valors emprats ($\lambda = 0.98$ en RL pur i $\lambda = 0.95$ en MPC+RL) s'han triat perquè donen entrenament estable en dos entorns amb escales temporals diferents (pas d'1 minut vs macro-pas de 60 minuts).

En comparació amb els treballs anteriors, la present memòria es diferencia en els aspectes següents: (1) el domini és una comunitat energètica real de Cornellà, amb perfils de generació i demanda específics; (2) es compara PPO directament amb un MPC greedy d'un sol pas implementat amb CVXPY; (3) es dona especial atenció al disseny de la funció de recompensa, en particular al tractament de la penalització per degradació i a la variabilitat dels preus.

2.4 Optimització amb CVXPY

CVXPY [Diamond 2016] és una biblioteca de Python per a la formulació i resolució de problemes d'optimització convexa. En aquest treball s'utilitza per implementar el controlador MPC, amb el solver CLARABEL com a motor d'optimització. CLARABEL [Goulart 2024] és un solver de codi obert per a problemes semidefinites i de segon ordre, que ofereix bon rendiment computacional per a problemes de mida mitjana.

2.5 Stable-Baselines3 i Gymnasium

L'entrenament de l'agent RL es realitza amb Stable-Baselines3 [Raffin 2021], una biblioteca que implementa algorismes RL estàndard (PPO, SAC, TD3, entre

d'altres) de forma robusta i ben documentada. L'entorn de simulació segueix la interfície de Gymnasium [Towers 2024], l'estàndard *de facto* per a entorns RL en Python.

CAPÍTOL 3

Preliminars

3.1 Domini: la comunitat energètica de Cornellà

La comunitat energètica objecte d'estudi es troba a Cornellà de Llobregat i és composta per:

- 20 habitatges unifamiliars amb perfils de consum sintètics estadísticament representatius.
- Una instal·lació fotovoltaica compartida de 15 kW de potència pic.
- Un BESS de 50 kWh de capacitat nominal amb un inversor de potència màxima 50 kW.

El simulador de la comunitat, desenvolupat per Martí Cabarrocas I Sánchez en el seu Treball de Fi de Grau, genera fitxers CSV diaris amb les sèries temporals de generació solar, demanda de l'escola, demanda agregada dels habitatges i preus de mercat PVPC horaris. Aquest simulador utilitza dades meteorològiques reals i perfils de consum sintètics estadísticament representatius.

3.2 Notació i definicions

Al llarg d'aquest document s'utilitza la notació següent:

- $t \in \{0, 1, \dots, T - 1\}$: índex de temps, amb granularitat d'1 minut ($T = 1440$ per un dia complet).
- $\text{SoC}_t \in [0, 1]$: estat de càrrega de la bateria al pas t , normalitzat sobre la capacitat de 50 kWh. Per preservar la vida útil s'imposen límits operatius $\text{SoC}_{\min} = 0.0$ i $\text{SoC}_{\max} = 1.0$.
- P_t^{gen} : potència generada pels panells fotovoltaics al pas t (kW).
- P_t^{dem} : potència total demandada per la comunitat al pas t (kW).
- P_t^{batt} : acció de control, potència de càrrega (positiu) o descàrrega (negatiu) del BESS (kW).

- p_t^+, p_t^- : preus de compra i venda d'electricitat al pas t (€/kWh), seguint el perfil PVPC dels CSVs.
- P_t^{net} : potència neta importada de la xarxa ($P_t^{\text{net}} > 0$) o exportada ($P_t^{\text{net}} < 0$).
- C_{bat} : capacitat màxima de la bateria (50 kWh).
- P_{max} : potència màxima de l'inversor (50 kW).
- η_c, η_d : rendiments de càrrega i descàrrega (en aquest TFM s'assumeix $\eta_c = \eta_d = 1$).
- $\Delta t = 1/60$ h: interval de temps entre passos (1 minut).

3.3 Dinàmica de la bateria

L'evolució de l'estat de càrrega entre dos passos consecutius segueix l'equació:

$$\text{SoC}_{t+1} = \text{SoC}_t + \frac{(P_t^{\text{batt}} \cdot \Delta t)}{C_{\text{bat}}} \quad (3.1)$$

L'acció de control ha de complir les restriccions:

$$-P_{\text{max}} \leq P_t^{\text{batt}} \leq P_{\text{max}} \quad (3.2)$$

$$\text{SoC}_{\text{min}} \leq \text{SoC}_{t+1} \leq \text{SoC}_{\text{max}} \quad (3.3)$$

on $\text{SoC}_{\text{min}} = 0.0$ i $\text{SoC}_{\text{max}} = 1.0$. En la implementació real del pipeline s'assumeix eficiència unitària, de manera que la bateria suma o resta energia de forma lineal: si $P_t^{\text{batt}} > 0$, la bateria es carrega; si $P_t^{\text{batt}} < 0$, la bateria es descarrega. El filtre de seguretat força que aquesta actualització no pugui portar el SoC fora del rang físic permès.

3.4 Funció de benefici econòmic

El codi no calcula el resultat econòmic només a partir del balanç net de la bateria, sinó del balanç complet de la comunitat. Primer es compensa internament l'energia entre l'escola i els habitatges; després només es comptabilitzen els fluxos reals amb la xarxa exterior. Això permet parlar d'**estalvi**: encara que el valor monetari per pas sigui sovint negatiu perquè la comunitat continua pagant electricitat, una estratègia és millor com més redueix aquesta pèrdua respecte a les alternatives.

Primer definim el balanç de l'escola:

$$P_{t,esc}^{bal} = P_t^{dem,esc} - P_t^{gen} + P_t^{batt} \quad (3.4)$$

amb la convenció següent:

- si $P_{t,esc}^{bal} > 0$, a l'escola li falta energia i ha de comprar-ne;
- si $P_{t,esc}^{bal} < 0$, a l'escola li sobra energia i primer es compensa internament amb les cases.

Definint també $P_{t,cas}^{bal} = P_t^{dem,cas}$, el benefici econòmic per minut queda:

$$b_t^{econ} = -\left(E_{t,buy}^{esc} \cdot p_t^+\right) + \left(E_{t,sell}^{esc} \cdot p_t^-\right) - \left(E_{t,buy}^{cas} \cdot p_t^+\right) \quad (3.5)$$

on $E_{t,buy}^{esc}$, $E_{t,sell}^{esc}$ i $E_{t,buy}^{cas}$ són, respectivament, l'energia (kWh en aquest minut) que l'escola compra, l'energia que l'escola ven i l'energia que les cases compren de la xarxa després del repartiment intern.

Interpretació directa de (3.5):

- termes amb signe negatiu ($-E \cdot p$): **costos** de compra a la xarxa;
- terme amb signe positiu ($+E \cdot p$): **ingrés** per venda d'excedents.

Per tant, l'estalvi augmenta quan la bateria redueix compres en hores cares i/o desplaça energia cap a franges amb més valor econòmic.

3.5 Model de preus i degradació

Durant l'entrenament i l'avaluació s'utilitzen els preus de compra i venda continguts als fitxers CSV generats pel simulador, és a dir, dues sèries temporals p_t^+ i p_t^- que l'entorn llegeix a cada minut. Els valors fixos de 0,120 €/kWh i 0,080 €/kWh existeixen al codi només com a mecanisme de reserva si algun CSV no contingués aquestes columnes. Per tant, el controlador aprèn sobre preus variables i no sobre un mercat completament pla.

La degradació de la bateria es modela com un cost lineal proporcional a l'energia que circula per la bateria:

$$c_{deg,t} = c_{deg} \cdot f_{SoC}(t) \cdot |P_t^{batt} \cdot \Delta t|, \quad c_{deg} = 0.002 \text{ €/kWh} \quad (3.6)$$

amb

$$f_{SoC}(t) = \begin{cases} 2 & \text{si } SoC_t < 0.05 \text{ o } SoC_t > 0.95 \\ 1 & \text{altrament} \end{cases} \quad (3.7)$$

Aquesta formulació lineal continua essent una aproximació conservadora, però el codi introdueix explícitament una penalització extra quan la bateria opera massa a prop dels extrems del SoC. En termes pràctics, això reforça la idea que no n'hi ha prou amb maximitzar ingressos: també cal preservar l'actiu i convertir el control en estalvi sostingut.

3.6 El Procés de Decisió de Markov (MDP)

El marc formal de l'Aprenentatge per Reforç és el *Procés de Decisió de Markov* (MDP) [Sutton 2018]. Un MDP es defineix com la tupla $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{T}, \mathcal{R}, \gamma)$, on:

- $\mathcal{S}$: espai d'estats (observacions que l'agent percep de l'entorn).
- $\mathcal{A}$: espai d'accions disponibles per a l'agent.
- $\mathcal{T}(s'|s, a) = P(s_{t+1} = s' \mid s_t = s, a_t = a)$: probabilitat de transició d'estat.
- $\mathcal{R}(s, a)$: recompensa esperada en prendre l'acció a a l'estat s .
- $\gamma \in [0, 1)$: factor de descàrrega per ponderar les recompenses futures.

Propietat de Markov. L'aspecte essencial dels MDP és que l'estat futur s_{t+1} depèn únicament de l'estat actual s_t i de l'acció a_t , i no de la seqüència d'estats i accions anteriors:

$$P(s_{t+1} \mid s_t, a_t, s_{t-1}, a_{t-1}, \dots) = P(s_{t+1} \mid s_t, a_t) \quad (3.8)$$

En el control del BESS, l'estat $s_t = [\text{SoC}_t, p_t^{\text{gen}}, p_t^{\text{dem,esc}}, p_t^{\text{dem,cas}}, p_t^+, p_t^-, \sin \theta_t, \cos \theta_t]$ conté tota la informació rellevant per a la decisió del pas t , de manera que el problema satisfà (aproximadament) la propietat de Markov: no cal recordar les accions passades per prendre la millor decisió present.

3.6.1 Cicle estat–acció–estat–recompensa

La Figura 3.1 mostra el cicle fonamental de la interacció entre l'agent i l'entorn a cada pas de temps t : l'agent observa l'estat s_t , selecciona l'acció a_t seguint la *policy* π_θ , i l'entorn genera el nou estat s_{t+1} i la recompensa r_{t+1} .




Figura 3.1: Cicle fonamental de l'MDP: l'agent en l'estat s_t selecciona una acció a_t seguint la *policy* π_θ ; l'entorn transita al nou estat s_{t+1} (distribució $\mathcal{T}$) i genera la recompensa r_{t+1} (funció $\mathcal{R}$). La fletxa discontinua representa el pas temporal que reinicia el cicle.

3.6.2 Diagrama agent–entorn

La Figura 3.2 mostra el diagrama canònic de la interacció agent–entorn en RL. La caixa de retard remarca que en problemes d'energia, l'efecte econòmic complet d'una acció (p.ex., carregar la bateria de nit a preu baix per descarregar-la al migdia a preu alt) pot no ser visible fins a passos de temps posteriors.




Figura 3.2: Diagrama canònic agent–entorn en RL aplicat al control del BESS. L'agent PPO genera l'acció de control $a_t \in [-1, 1]$ (fracció de potència màxima); l'entorn (BessEnv) executa la dinàmica de la bateria, calcula la recompensa econòmica r_{t+1} i retorna el nou estat s_{t+1} . La caixa discontinua recorda que les decisions actuals poden tenir efectes econòmics visibles en passos posteriors (*delayed reward*).

L'objectiu de l'agent és aprendre la *policy* π_θ^* que maximitzi el retorn acumulat esperat descomptat:

$$J(\theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{t=0}^T \gamma^t r_{t+1} \right] \quad (3.9)$$

on γ^t pondera cada recompensa futura r_{t+1} amb un pes decreixent: les recompenses properes valen més que les llunyanes. Maximitzar $J(\theta)$ és equivalent a trobar la *policy* que obté el major estalvi econòmic acumulat al llarg d'un dia sencer. La funció d'avantatge $A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$ mesura la millora rela-

tiva d'una acció concreta respecte a la *policy* actual, i és el senyal que guia les actualitzacions de l'actor en els algoritmes actor-crític com PPO.

3.7 Aprenentatge per reforç: PPO

Proximal Policy Optimization (PPO) [Schulman 2017] és un algoritme RL de tipus *actor-crític* basat en gradients de *policy*, dissenyat per garantir actualitzacions estables de la *policy* gràcies a una restricció sobre la magnitud del canvi en cada iteració. La funció objectiu de PPO és:

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_t \right) \right] \quad (3.10)$$

on $r_t(\theta) = \pi_\theta(a_t|s_t)/\pi_{\theta_{\text{old}}}(a_t|s_t)$ és el ràtio de probabilitats, $\hat{A}_t$ és l'estimació de l'avantatge i ε és un hiperparàmetre de restricció (típicament 0.2) es a dir, si una acció va ser millor del previst ($\hat{A}_t > 0$), PPO augmenta la seva probabilitat, però només fins a un factor $1 + \varepsilon$; si va ser pitjor ($\hat{A}_t < 0$), la redueix, però no per sota de $1 - \varepsilon$. El min garanteix que mai s'aprofita un avantatge positiu per fer un pas massa gran. Aquesta restricció evita que el gradient s'apliqui de forma excessiva en un sol *rollout*, cosa especialment rellevant en episodis de 1440 passos com els d'aquest TFM, on la variança de les estimacions és alta.

3.8 Control Predictiu basat en Model (MPC)

El MPC estàndard resol en cada pas de temps t el problema d'optimització:

$$\begin{aligned} \max_{p_{\tau}^{\text{batt}}} \quad & \sum_{\tau=t}^{t+H-1} \gamma^{\tau-t} \cdot b_{\tau} \\ \text{subjecte a} \quad & (3.1), (3.2), (3.3) \end{aligned} \quad (3.11)$$

on H és l'horitzó de predicció i b_{τ} és el benefici al pas τ . En aquest TFM s'avaluen dues variants: el MPC greedy ($H = 1$), que optimitza únicament el benefici del pas actual i serveix com a línia base, i el MPC amb horitzó de 60 minuts ($H = 60$), que incorpora una finestra de planificació equivalent a una hora. Ambdós es comparen amb el RL pur i amb l'arquitectura híbrida. El paper del MPC com a *tracker* de baixa latència dins de l'arquitectura MPC+RL s'explica al Capítol 5.

Planificació i Metodologia

4.1 Metodologia de desenvolupament

El projecte s'ha desenvolupat seguint una metodologia iterativa i experimental, pròpia de la ciència de dades. Les fases principals han estat:

1. **Familiarització amb el simulador:** comprensió del simulador de la comunitat energètica (codi de Martí Cabarrocas I Sánchez), format dels CSV generats i paràmetres configurables.
2. **Implementació del pipeline bàsic:** disseny de l'estructura de fitxers (`params.py`, `utils.py`, `src/`), implementació del filtre de seguretat i de la dinàmica de la bateria.
3. **Implementació del controlador MPC:** formulació del problema de CVXPY i integració del solver CLARABEL.
4. **Disseny de l'entorn RL:** implementació de `BessEnv` com a entorn `Gymnasium`, definició de l'espai d'observació i d'acció.
5. **Entrenament i ajust de PPO:** experimentació amb la funció de recompensa, normalització d'observacions i hiperparàmetres.
6. **Avaluació comparativa:** execució del pipeline complet sobre el conjunt de test i anàlisi de resultats.

4.2 Estructura del codi

El codi del projecte s'organitza de la manera següent:

- `params.py`: paràmetres compartits de la bateria, l'inversor i la normalització d'observacions.
- `src/utils.py`: funcions auxiliars (filtre de seguretat, dinàmica de la bateria, càlcul econòmic).

- `src/controllers/mpc.py`: implementació del controlador MPC greedy amb CVXPY.
- `src/controllers/rl.py`: `RLController` per a la inferència del model PPO entrenat.
- `src/train_rl.py`: entorn `BessEnv` i script d'entrenament PPO.
- `src/main_evaluation.py`: pipeline d'avaluació comparativa MPC vs RL.
- `Simulador_comunitat/simulation_2.py`: simulador de la comunitat (codi de Martí Cabarrocas I Sánchez).
- `run_pipeline.py`: orquestrador dels 4 passos del pipeline.

4.3 Planificació temporal

La Taula 4.1 resumeix la planificació prevista i la real del projecte.

Fase	Previst (setmanes)	Real (setmanes)
Familiarització amb el simulador	1	2
Implementació del pipeline bàsic	2	2
Implementació MPC	1	1
Disseny de l'entorn RL	2	3
Entrenament i ajust PPO	3	4
Avaluació i anàlisi	1	2
Redacció de la memòria	2	2
Total	12	16

Taula 4.1: Planificació temporal prevista vs real del projecte.

El principal desviament es deu al temps dedicat a la identificació i correcció d'errors en el disseny de la funció de recompensa i en la normalització de les observacions, que van requerir diverses iteracions d'experimentació.

4.4 Costos del projecte

Els costos principals del projecte han estat:

- **Recursos humans:** 400 hores de treball a 15 €/hora = 6.000 €.

- **Infraestructura de còmput:** entrenament RL en CPU local (MacBook Pro); cost d'amortització inclòs en el cost per hora.
- **Eines de software:** totes les biblioteques utilitzades (CVXPY, Stable-Baselines3, Gymnasium, Pandas, Matplotlib) són de codi obert i gratuïtes.
- **Cost total estimat:** 6.000 €.

Contribució Metodològica

5.1 Arquitectura del sistema

La Figura 5.1 mostra l'arquitectura general del sistema. El simulador de la comunitat genera els CSV diaris, que s'utilitzen tant per entrenar l'agent RL (en mode *offline*, recorrent el conjunt d'entrenament) com per avaluar els dos controladors (en mode d'inferència sobre el conjunt de test).




Figura 5.1: Arquitectura del sistema. El simulador genera CSVs diaris; l'agent PPO s'entrena sobre el conjunt d'entrenament i, en inferència, el controlador RL pur proposa una acció directa a_t , mentre que el controlador MPC+RL proposa un SoC objectiu cada 60 minuts que un *tracker* MPC segueix minut a minut.

5.2 Entorn de simulació RL (BessEnv)

L'entorn BessEnv implementa la interfície de Gymnasium i encapsula la dinàmica de la bateria i la lògica de recompensa. Els seus elements principals són:

5.2.1 Espai d'observació

El vector d'observació $s_t \in [0, 1]^6 \times [-1, 1]^2$ conté les variables normalitzades que l'agent percep a cada pas de temps. Les variables i les seves constants de normalització (definides a `params.py`) es recullen a la Taula 5.1.

La codificació cíclica del temps ($\sin / \cos$) permet a l'agent percebre la naturalesa periòdica del dia sense discontinuïtats. En paraules, l'observació resumeix l'estat energètic actual, la càrrega de la comunitat, els dos preus de mercat i el moment del dia en què s'ha de prendre la decisió.

Variable	Descripció	Normalització
SoC_t	Estat de càrrega de la bateria	$[0, 1]$ (directe)
$P_t^{\text{gen}}/P_{\text{max}}$	Generació solar normalitzada	$P_{\text{max}} = 50 \text{ kW}$
$P_t^{\text{dem,esc}}/D_{\text{max}}^{\text{esc}}$	Demanda escola normalitzada	$D_{\text{max}}^{\text{esc}} = 20 \text{ kW}$
$P_t^{\text{dem,cas}}/D_{\text{max}}^{\text{cas}}$	Demanda habitatges normalitzada	$D_{\text{max}}^{\text{cas}} = 40 \text{ kW}$
p_t^+/p_{max}	Preu de compra normalitzat	$p_{\text{max}} = 0.5 \text{ €/kWh}$
p_t^-/p_{max}	Preu de venda normalitzat	$p_{\text{max}} = 0.5 \text{ €/kWh}$
$\sin(2\pi t/T)$	Component sinusoidal del temps	Codificació cíclica
$\cos(2\pi t/T)$	Component cosinusoidal del temps	Codificació cíclica

Taula 5.1: Variables d'observació i constants de normalització.

5.2.2 Espai d'acció

L'espai d'acció és continu: $a_t \in [-1, 1]$, on $a_t = 1$ correspon a càrrega màxima ($+P_{\text{max}}$) i $a_t = -1$ a descàrrega màxima ($-P_{\text{max}}$). Un filtre de seguretat (`filtro_seguridad`) comprova que l'acció resultant no viola els límits de SoC i la trunca si cal.

5.2.3 Funció de recompensa

En l'entorn RL pur, la *reward function* no és un benefici absolut positiu, sinó una mesura d'estalvi operatiu instantani. La comunitat gairebé sempre té un cost elèctric residual, de manera que molts valors continuen sent negatius; el que importa és que siguin **menys negatius**, és a dir, que la política redueixi la despesa respecte a estratègies pitjors.

La implementació exacta és:

$$r_t = \frac{b_t^{\text{econ}} - (\beta_{\text{deg}} \cdot c_{\text{deg},t}) - (\beta_{\text{clip}} \cdot \text{clip}_t)}{s_r} \quad (5.1)$$

on b_t^{econ} és el balanç econòmic del minut, $c_{\text{deg},t}$ és el cost de degradació de l'Equació (3.6), clip_t mesura quant s'ha retallat l'acció demanada pel filtre de seguretat, $\beta_{\text{deg}} = 8.0$, $\beta_{\text{clip}} = 0.05$ i $s_r = 5.0$ és un factor d'escala numèrica. En concret, *clipping* vol dir que l'agent ha demanat una acció fora dels límits físics i el filtre l'ha hagut de reduir a un valor viable. Les constants β_{deg} i β_{clip} no són paràmetres físics de la bateria, sinó **pesos de disseny de la recompensa**: indiquen quanta importància relativa es dona, durant l'entrenament, a penalitzar la degradació i a penalitzar les accions inviables corregides pel filtre. En particular, β_{deg} és molt més gran que β_{clip} perquè es vol desincentivar amb força el ciclatge excessiu, mentre que el retall del filtre només actua com una correcció suau.

Expressat amb paraules, la *reward function* premia decisions que redueixen

la factura de la comunitat, però resta punts quan aquesta millora s'aconsegueix a costa de ciclar massa la bateria o de demanar accions inviables que el filtre ha de corregir. Aquesta formulació força l'agent a aprendre estalvi útil, no només moviment de bateria.

5.2.4 Funció de recompensa de l'entorn MPC+RL

En l'entorn jeràrquic MPC+RL, l'agent no tria directament una potència de bateria a cada minut, sinó un SoC objectiu per al següent macro-pas de 60 minuts. Per això, la *reward function* d'entrenament també canvia: en lloc de valorar un únic minut, acumula el guany marginal del bloc complet respecte a l'escenari sense bateria.

La implementació exacta és:

$$r_t^{\text{MPC+RL}} = \sum_{i=0}^{59} \left[(b_{t+i}^{\text{econ}} - b_{t+i}^{\text{base}}) - (\beta_{\text{deg}}^{\text{hyb}} \cdot c_{\text{deg},t+i}) - (\beta_{\text{clip}} \cdot \text{clip}_{t+i}) \right] \quad (5.2)$$

on b_{t+i}^{base} és el benefici econòmic del mateix minut en l'escenari sense bateria, $\beta_{\text{deg}}^{\text{hyb}} = 3.0$ i $\beta_{\text{clip}} = 0.05$. Igual que en l'entorn RL pur, aquestes betes són pesos heurístics de la *reward function* i no propietats físiques del sistema. En la implementació, aquest valor agregat no s'escala addicionalment ($s_r = 1.0$).

Interpretat amb paraules, l'agent MPC+RL rep recompensa positiva quan el SoC objectiu proposat fa que el *tracker* MPC millori el resultat econòmic del bloc d'una hora respecte a no tenir bateria. Això fa que l'agent aprengui decisions de planificació a escala horària, mentre el MPC s'encarrega del seguiment minut a minut i del compliment de restriccions.

5.3 Controlador MPC greedy

El controlador MPC implementat a `src/controllers/mpc.py` resol en cada pas de temps el problema:

$$\max_{p_t^{\text{batt}}, E_t^{\text{buy}}, E_t^{\text{sell}}} p_t^- \cdot E_t^{\text{sell}} - p_t^+ \cdot E_t^{\text{buy}} - \alpha \cdot |p_t^{\text{batt}}| \cdot \Delta t \quad (5.3)$$

$$\text{subjecte a} \quad -P_{\text{max}} \leq P^{\text{batt}} \leq P_{\text{max}} \quad (5.4)$$

$$\text{SoC}_{\text{min}} \leq \text{SoC}_t + \frac{(P_t^{\text{batt}} \cdot \Delta t)}{C_{\text{bat}}} \leq \text{SoC}_{\text{max}} \quad (5.5)$$

$$E_t^{\text{buy}} - E_t^{\text{sell}} = (D_t^{\text{esc}} - G_t + P_t^{\text{batt}}) \cdot \Delta t, \quad E_t^{\text{buy}} \geq 0, E_t^{\text{sell}} \geq 0 \quad (5.6)$$

on p_t^+ i p_t^- són els preus de compra i venda, E_t^{buy} i E_t^{sell} són les energies importades i exportades en el minut, D_t^{esc} és la demanda de l'escola, G_t és la generació fotovoltaica i α és el cost de degradació per unitat d'energia processada.

5.4 Entrenament de l'agent PPO

5.4.1 Divisió entrenament / validació (80 % / 20 %)

L'entrenament s'ha realitzat sobre un conjunt de dades generat pel simulador de la comunitat energètica de Martí Cabarrocas I Sánchez per a un total de 7.300 dies (20 anys de simulació). Seguint la pràctica estàndard en aprenentatge automàtic, els dies s'han ordenat cronològicament i dividit en:

- **Conjunt d'entrenament** (80 %): els primers 5.840 dies. L'agent PPO explora i aprèn la *policy* sobre aquest conjunt. Durant l'entrenament, a cada restabliment d'episodi es tria un dia aleatori d'aquest bloc, afavorint la diversitat d'experiències.
- **Conjunt de test** (20 %): els darrers 1.460 dies. Aquest bloc **no s'utilitza mai durant l'entrenament**; únicament s'emptra per a l'avaluació final comparativa (Capítol 6), garantint que els resultats reflecteixen el rendiment en condicions no vistes.

La divisió cronològica (no aleatòria) és intencional: evita la fuga d'informació temporal (*data leakage*) que es produiria si els dies de test s'intercalessin amb els d'entrenament. El codi que implementa aquesta divisió és la funció `cargar_dataset(split, train_ratio=0.8)` a `src/models/train_rl.py`.

L'agent PPO s'entrena sobre els dies del conjunt d'entrenament (primer 80 % dels dies disponibles), iterant sobre cada dia complet com a episodi. Els hiperparàmetres principals es recullen a la Taula 5.2.

Hiperparàmetre	Valor
Algoritme	PPO (Stable-Baselines3)
Arquitectura de la xarxa	MLP (<i>Multi-Layer Perceptron</i>); actor [64], crític [64, 64]
Funció d'activació	funció d'activació ReLU (<i>Rectified Linear Unit</i>)
Taxa d'aprenentatge (α)	3×10^{-4}
Grandària del lot	288
Passos per actualització	5760
Nombre d'èpocs	10
Factor de descompte (γ)	0.999
GAE- λ	0.98
Coefficient de restricció (ϵ)	0.2
Coefficient d'entropia	0.01
Passos totals d'entrenament	2.000.000

Taula 5.2: Hiperparàmetres de l'entrenament PPO.

5.4.2 Implementació real de PPO al projecte

Per fer aquesta secció més directa i verificable, en lloc de pseudocodi abstracte es mostra un fragment de codi real utilitzat en aquest TFM (`fixer/src/models/train_rl.py`):

```
model = PPO(
    "MlpPolicy",
    env,
    verbose=1,
    learning_rate=3e-4,
    n_steps=EPISODE_LEN * 4,
    batch_size=288,
    n_epochs=10,
    gamma=0.999,
    gae_lambda=0.98,
    clip_range=0.2,
    ent_coef=0.01,
    use_sde=True,
    sde_sample_freq=4,
    policy_kwargs={"activation_fn": nn.ReLU,
                  "net_arch": {"pi": [64], "vf": [64, 64]}}),

timesteps_totales = 2_000_000
model.learn(total_timesteps=timesteps_totales)
```

5.5 Decisions de disseny crítiques

Durant el desenvolupament s'han identificat i resolt diverses dificultats tècniques:

- **Penalització de degradació excessiva:** un pes massa alt de la degradació conduïa l'agent a una *policy* d'inacció. Després de diverses proves, els valors finals es van fixar a $\text{DEG_PENALTY_MULT} = 8.0$ per a l'agent RL pur i $\text{DEG_PENALTY_MULT} = 3.0$ per al controlador MPC+RL, on la recompensa és més agregada i marginal.
- **Preus plans:** la implementació inicial del simulador usava preus constants, eliminant el senyal d'aprenentatge temporal. Es va corregir per treballar amb les sèries temporals de preus presents als CSVs, amb variació al llarg del dia.
- **Normalització de les observacions:** les observacions sense normalitzar causaven inestabilitat en l'entrenament. Es van normalitzar totes les variables a $[0, 1]$ usant constants físicament motivades.
- **Coefficient del filtre de seguretat:** $\text{FILTER_PENALTY_COEF}$ reduït de 0.5 a 0.05 per evitar penalitzar excessivament accions segures prop dels límits de SoC.

CAPÍTOL 6

Resultats

6.1 Controladors avaluats

S'han avaluat quatre estratègies de control:

- **MPC(H=1)**: MPC greedy d'un sol pas. Optimitza únicament el benefici immediat del pas actual, sense cap horitzó de predicció.
- **MPC(H=60)**: MPC amb horitzó de 60 minuts. Resol un problema d'optimització de 60 passos en cada iteració, considerant la generació i la demanda futures dins d'aquest horitzó.
- **RL (PPO)**: agent d'aprenentatge per reforç entrenat amb l'algoritme PPO sobre el conjunt d'entrenament (80% dels dies).
- **MPC+RL**: arquitectura híbrida de tipus *RL-guided MPC*. L'agent RL proposa un SoC objectiu cada 60 minuts, i un *tracker* MPC amb horitzó 60 calcula la seqüència de potències que millor s'hi ajusta minimitzant el cost net de transaccions i la desviació final del SoC.

6.2 Configuració experimental

Els experiments s'han executat sobre el conjunt de test, format pel darrer 20% dels dies simulats (1460 dies de 7300 totals). Les mètriques d'avaluació principals són:

- **Benefici de transaccions (€)**: ingressos per venda d'energia menys cost de compra a la xarxa.
- **Cost de degradació (€)**: cost acumulat de ciclatge de la bateria ($c_{deg} \cdot f_{SoC} \cdot \text{energia processada}$).
- **Benefici net (€)**: benefici de transaccions menys cost de degradació.
- **Cicles de bateria (cicles)**: nombre de cicles complets de càrrega/descàrrega induïts.

- **SoC mitjà**: estat de càrrega mitjà al llarg del període d'avaluació.
- **Temps de decisió (ms)**: latència computacional per pas de temps.

6.3 Resultats sobre el conjunt de test complet (1.460 dies)

La Taula 6.1 recull els resultats de l'avaluació completa sobre el conjunt de test (1.460 dies, 2.102.400 minuts de simulació, corresponents al 20% final dels 7.300 dies totals generats).

Mètrica	MPC(H=1)	MPC(H=60)	RL	MPC+RL
Benefici transaccions (€)	-97.826,56	-97.059,70	-93.053,40	-84.663,27
Cost degradació (€)	-0,00	-442,55	-981,38	-2.479,11
Benefici net (€)	-97.826,56	-97.502,25	-94.034,78	-87.142,38
Energia carregada (kWh)	0,0	12.365,7	44.583,0	97.526,5
Energia descarregada (kWh)	0,0	12.365,7	44.580,6	97.526,5
Cicles complets	0,0	247,3	891,7	1.950,5
SoC mitjà	0,000	0,010	0,230	0,705
% temps carregant	0,0%	3,9%	23,7%	11,6%
% temps descarregant	0,0%	3,7%	17,4%	15,9%
% temps inactiu	100,0%	92,4%	58,9%	72,5%
Temps decisió (ms)	0,629	3,768	0,132	2,059

Taula 6.1: Resultats comparatius sobre el conjunt de test complet (1.460 dies, 2.102.400 passos de temps).

6.4 Evolució de l'entrenament

La Figura 6.1 mostra l'evolució de la recompensa mitjana per episodi al llarg de l'entrenament de l'agent PPO.

Les corbes mostren la recompensa mitjana per episodi (*rolling mean* calculada per Stable-Baselines3 sobre els darrers episodis) en funció del nombre de timesteps d'entrenament. Es considera que hi ha convergència quan la recompensa s'estabilitza i l'*explained variance* s'aproxima a 1, la qual cosa indica que el crític prediu correctament els retorns.

En aquest TFM s'ha realitzat una única execució per limitació de temps computacional (entrenament en CPU), de manera que les corbes de la Figura 6.1 mostren la trajectòria d'una sola run sense banda de confiança. Per tant, aquí no




Figura 6.1: Corbes d'aprenentatge de l'agent PPO i del controlador MPC+RL durant l'entrenament. El panell superior mostra la recompensa mitjana per episodi, i el panell inferior l'*explained variance* del crític, utilitzada com a indicador de convergència.

es representa cap interval del 95 %; aquesta referència només tindria sentit en un experiment amb múltiples execucions independents i es deixa com a possible extensió futura.

6.5 Anàlisi del comportament diari

6.6 Estudi d'ablació: funció d'activació i GAE- λ

Per avaluar la robustesa de les decisions de disseny de la xarxa neuronal de l'agent MPC+RL, s'ha dut a terme un estudi d'ablació sistemàtic sobre l'entorn de macro-pas (60 min/acció): 4 funcions d'activació (ReLU, Leaky ReLU, ELU, Tanh) $\times$ 2 valors del paràmetre GAE- λ (0.95 i 1.00), cadascuna entrenada durant 500.000 timesteps amb els mateixos hiperparàmetres i el mateix 80 % d'entrenament. La recompensa representa el guany marginal respecte a l'escenari sense bateria; per tant, valors positius indiquen que la bateria aporta valor.

La Figura 6.3 mostra les corbes d'aprenentatge resultants, i la Taula 6.2 recull




Figura 6.2: Comportament d'un dia típic d'estiu (dia 93 del conjunt de test). *Dalt*: evolució del SoC de la bateria per als quatre controladors al llarg de les 24 hores. *Centre*: potència de bateria (positiu = càrrega; negatiu = descàrrega). *Baix*: generació fotovoltaica i demanda total de la comunitat (kW).

les recompenses finals.

Les conclusions de l'estudi d'ablació sobre el model MPC+RL són:

1. **Totes les configuracions convergeixen a valors similars.** El rang total entre la millor i la pitjor configuració és d'únicament 0,48 punts sobre una recompensa de $\approx 6,8$, menys d'un 7 % de variació relativa. Això indica que el *tracker* MPC simplifica la tasca de l'agent i el fa força robust a la tria d'hiperparàmetres de la xarxa.
2. **GAE- λ no és el factor dominant en el model MPC+RL.** A diferència de l'entorn de pas minut, on λ tenia un impacte de 8 punts, aquí les configuracions $\lambda = 0.95$ i $\lambda = 1.00$ apareixen barrejades al rànquing. Amb episodis




Figura 6.3: Estudi d'ablació sobre el model MPC+RL (500.000 timesteps, macro-pas 60 min). *Esquerra*: efecte de la funció d'activació amb $\lambda = 0,95$. *Dreta*: efecte del paràmetre GAE- λ amb activació ReLU. La recompensa representa el guany marginal respecte a l'escenari sense bateria. La línia gruixuda correspon a la mitjana mòbil (finestra de 7 episodis) i la banda ombrejada mostra l'interval de confiança del 95 % ($\bar{x} \pm 1,96 \sigma$) de la variabilitat observada durant l'entrenament.

de 24 macro-passos (24 hores), els retorns Monte Carlo purs ($\lambda = 1.00$) no acumulen tanta variança com en episodis de 1440 passos.

3. **ReLU amb $\lambda = 0,95$ és la configuració original i pràcticament òptima.** Ocupa la segona posició, empatat estadísticament amb Tanh (6,816 vs 6,828, diferència $< 0,2\%$). ELU resulta la pitjor opció en aquest entorn, al contrari del que succeïa en el model de pas minut.
4. **Validació de les decisions de disseny.** L'arquitectura MPC+RL d'aquest TFM utilitza ReLU i $\lambda = 0,95$, configuració que obté el segon millor resultat i és estadísticament indistingible del millor. L'ablació confirma que les decisions de disseny originals eren encertades i que el sistema és robust a canvis en aquests hiperparàmetres.

6.7 Discussió

Els resultats de la Taula 6.1 sobre 1.460 dies confirmen el rànking: MPC+RL $>$ RL $>$ MPC(H=60) $>$ MPC(H=1).

- **MPC(H=1) és completament inactiu.** Durant tots els 1.460 dies de test, el controlador greedy d'un sol pas no acciona mai la bateria (0 kWh carregats/descarregats, 100% del temps inactiu). Atès que el preu de venda

Activació	GAE- λ	Reward final	Reward màxim
Tanh	0.95	6,828	6,879
ReLU	0.95	6,816	6,872
Leaky ReLU	1.00	6,671	6,770
Tanh	1.00	6,661	6,726
Leaky ReLU	0.95	6,498	6,611
ReLU	1.00	6,406	6,596
ELU	1.00	6,387	6,496
ELU	0.95	6,352	6,575

Taula 6.2: Resultats de l'estudi d'ablació sobre el model MPC+RL (500K timesteps, macro-pas 60 min). La recompensa és el guany marginal respecte a l'escenari sense bateria; valors més positius indiquen millor rendiment.

(0,080 €/kWh) és inferior al de compra (0,120 €/kWh), el benefici net immediat de qualsevol moviment de bateria sense excedent fotovoltaic és negatiu. Sense horitzó de predicció, el MPC(H=1) no pot anticipar períodes favorables i opta sistemàticament per la inacció. Constitueix la cota inferior del sistema: el cost de no tenir cap estratègia de control.

- **MPC(H=60) millora de forma marginal.** L'horitzó de 60 minuts permet anticipar la generació solar propera i actua el 7,6% del temps, però el benefici net millora únicament en **324 € (0,3%)** respecte a MPC(H=1) al llarg de 1.460 dies (0,22 €/dia). El cost de degradació (442,55 €, 247 cicles) redueix dràsticament el guany brut en transaccions (766,86 €), deixant un benefici net addicional molt petit.
- **RL supera clarament el MPC(H=60).** L'agent PPO obté un benefici net de -94.034,78 €, millorant en **3.791,78 € (3,9%)** respecte a MPC(H=1), equivalent a **2,60 €/dia d'estalvi**. El resultat més destacat és la quasi-perfecta simetria entre energia carregada i descarregada: 44.583,0 vs 44.580,6 kWh (diferència de tan sols 2,4 kWh en 1.460 dies), fet que indica que l'agent ha après una *policy* de ciclatge estructuralment estable. El RL manté un SoC mitjà de 0,230 i actua el 41,1% del temps (23,7% carregant i 17,4% descarregant).
- **MPC+RL és el millor en totes les mètriques econòmiques.** L'arquitectura híbrida assoleix -87.142,38 € de benefici net: **10.684,18 € menys de pèrdua (10,9%)** que el MPC(H=1), equivalents a **7,32 €/dia d'estalvi**, i **6.892,40 € millor que el RL en solitari** (4,72 €/dia addicionals). El *tracker* MPC garanteix una simetria perfecta de la càrrega i la descàrrega (97.526,5 kWh en ambdues direccions) i un SoC mitjà de 0,705, cosa que

reflecteix un ús eficient i sostingut de la capacitat de la bateria. A canvi d'un cost de degradació de 2.479,11 € (1.950 cicles en 1.460 dies, 1,34 cicles/dia), el benefici brut de transaccions millora en 13.163,29 €.

- **Velocitat computacional.** El RL és el controlador més ràpid (0,132 ms/pas), seguit del MPC(H=1) (0,629 ms), MPC+RL (2,059 ms) i MPC(H=60) (3,768 ms). Tots quatre operen molt per sota de la granularitat d'1 minut, compatibles amb l'operació en temps real.

La Taula 6.3 resumeix l'estalvi net de cada controlador respecte a la inacció total, tant en termes absoluts com relatius i diaris.

Controlador	Benefici net (€)	Estalvi total (€)	Millora (%)	Estalvi/dia (€)
MPC(H=1) — cota inf.	-97.826,56	0,00	0,0%	0,00
MPC(H=60)	-97.502,25	+324,31	+0,3%	+0,22
RL (PPO)	-94.034,78	+3.791,78	+3,9%	+2,60
MPC+RL	-87.142,38	+10.684,18	+10,9%	+7,32

Taula 6.3: Estalvi net sobre el conjunt de test complet (1.460 dies) respecte al MPC(H=1).

Les principals limitacions d'aquest anàlisi són: (1) els preus utilitzats provenen dels CSVs del simulador i no d'una connexió directa amb el mercat real en línia, de manera que el valor de l'arbitratge temporal continua depenent del realisme d'aquestes sèries; (2) el model de degradació lineal no captura efectes de profunditat de descàrrega (DoD) ni de temperatura, de manera que el cost real de degradació del MPC+RL (1,34 cicles/dia) podria ser superior al que aquí s'estima.

Conclusions i treball futur

7.1 Resum de les contribucions

Aquest TFM ha abordat el problema del control segur i econòmicament eficient d'un BESS de 50 kWh en una comunitat energètica formada per 20 habitatges i una instal·lació fotovoltaica compartida de 15 kW. Les contribucions principals han estat:

1. El disseny i la implementació d'un **entorn de simulació RL** (BessEnv, Gymnasium) integrat amb el simulador de comunitat energètica de Martí Cabarrocas I Sánchez, amb model de degradació lineal i normalització d'observacions.
2. La implementació de **quatre controladors comparables**: MPC(H=1), MPC(H=60), RL (PPO) i l'arquitectura híbrida MPC+RL.
3. L'ajust rigorós de la funció de recompensa i dels hiperparàmetres de PPO per evitar la *policy* d'inacció i garantir l'aprenentatge d'estratègies actives.
4. La validació que l'**arquitectura híbrida MPC+RL** és la més eficient sobre 1.460 dies de test: -87.142 € de benefici net, reduint la pèrdua en 10.684 € (10,9%) respecte al MPC(H=1) i en 6.892 € respecte al RL en solitari.

7.2 Avaluació crítica dels resultats

Els resultats sobre el conjunt de test complet (1.460 dies) estableixen un rànquing clar i robust: **MPC+RL > RL > MPC(H=60) > MPC(H=1)**. Els aspectes més rellevants són els següents:

- L'arquitectura híbrida MPC+RL supera tots els controladors alternatius en benefici net, amb una millora del 10,9% sobre la inacció total.
- L'agent RL supera el MPC(H=60) en 3.468 € malgrat no tenir accés explícit a previsions de generació i demanda, demostrant la capacitat de generalització de la *policy* apresada.

- La simetria quasi-perfecta del RL (44.583,0 vs 44.580,6 kWh en 1.460 dies) i la simetria exacta del MPC+RL indiquen *polícies* molt ben calibrades.
- Tots els controladors operen en temps real ($\ll$ 1 minut per pas de decisió).

Les limitacions principals són les següents:

- El MPC(H=1) és completament inactiu, la qual cosa el converteix en una cota inferior i no en una línia base competitiva. El MPC(H=60) és la referència més rellevant.
- Els preus provenen d'un simulador offline i no d'una interfície directa amb el mercat real en línia; per tant, els resultats depenen de la qualitat i representativitat d'aquestes sèries temporals.
- El model de degradació lineal és una aproximació conservadora que no captura efectes de DoD ni temperatura; el cost real de degradació del MPC+RL (1,34 cicles/dia) mereixeria un model electroquímic més detallat.

7.3 Consideracions ètiques i legals

Pel que fa a consideracions ètiques, aquest projecte no involucra dades personals ni privades: les dades de consum i generació simulades són sintètiques i no permeten la identificació de persones. La gestió d'una comunitat energètica real requeriria, però, el consentiment informat dels membres i el compliment del Reglament General de Protecció de Dades (RGPD) en cas de processar dades de consum individuals.

Des del punt de vista legal, el desplegament d'un sistema de control autònom sobre infraestructures energètiques compartides estaria subjecte a la normativa d'autoconsum (Reial Decret 244/2019) i a les condicions de connexió a la xarxa establertes per l'operador de distribució.

7.4 Treball futur

Les línies de treball futur més prometedores identificades en aquest TFM són:

- **MPC amb horitzó real:** implementar un MPC amb horitzó de 24 hores i previsions de generació i demanda per disposar d'una línia base més exigent.

- **Millora de l'arquitectura híbrida:** ampliar el controlador actual incorporant previsions explícites, objectius multi-criteri o una penalització terminal més rica per millorar el seguiment del SoC objectiu.
- **Algoritmes alternatius:** explorar SAC (*Soft Actor-Critic*) o TD3, que poden oferir millor exploració i estabilitat d'entrenament en espais d'acció continus.
- **Dades reals:** validar el sistema amb dades reals de consum i generació de la comunitat energètica de Cornellà.
- **Multi-agent RL:** en escenaris amb múltiples BESS distribuïts, explorar enfocaments d'aprenentatge per reforç multi-agent (MARL) per coordinar els sistemes d'emmagatzematge.
- **Validació en living lab (Exit, UdG):** com a primer pas cap al desplegament real, es proposa una primera prova experimental a la instal·lació del parc tecnològic Exit de la Universitat de Girona. Exit disposa d'un entorn de microxarxa real amb panells fotovoltaics, sistema d'emmagatzematge i connexió a la xarxa de distribució. Aquesta instal·lació permetria validar el controlador MPC+RL en condicions reals de generació i demanda, quantificant el *sim-to-real gap* i identificant les discrepàncies entre el comportament simulat i el real que caldria corregir per al desplegament definitiu.

Bibliografia

- [Camacho 2007] Eduardo F. Camacho and Carlos Bordons. *Model predictive control*. Springer, London, 2nd edition, 2007. (Cited on page 5.)
- [Diamond 2016] Steven Diamond and Stephen Boyd. *CVXPY: A Python-Embedded Modeling Language for Convex Optimization*. *Journal of Machine Learning Research*, vol. 17, no. 83, pages 1–5, 2016. (Cited on page 8.)
- [Fujimoto 2018] Scott Fujimoto, Herke van Hoof and David Meger. *Addressing Function Approximation Error in Actor-Critic Methods*. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pages 1587–1596. PMLR, 2018. (Cited on page 6.)
- [Garcia 1989] Carlos E. Garcia, David M. Prett and Manfred Morari. *Model predictive control: theory and practice — a survey*. *Automatica*, vol. 25, no. 3, pages 335–348, 1989. (Cited on page 5.)
- [Goulart 2024] Paul J. Goulart and Yuwen Chen. *CLARABEL: An Interior-Point Solver for Conic Programs with Quadratic Objectives*. *arXiv preprint*, vol. arXiv:2212.09170, 2024. (Cited on page 8.)
- [Haarnoja 2018] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel and Sergey Levine. *Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor*. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pages 1861–1870. PMLR, 2018. (Cited on page 7.)
- [Koirala 2016] Binod Prasad Koirala, Elta Koliou, Jonas Friege, Rudi A. Hakvoort and Paulien M. Herder. *Energetic communities for community energy: A review of key issues and trends shaping integrated community energy systems*. *Renewable and Sustainable Energy Reviews*, vol. 56, pages 722–744, 2016. (Cited on page 5.)
- [Lillicrap 2016] Timothy P. Lillicrap, Jonathan J. Hunt, Alexander Pritzel, Nicolas Heess, Tom Erez, Yuval Tassa, David Silver and Daan Wierstra. *Continuous Control with Deep Reinforcement Learning*. *International Conference on Learning Representations (ICLR)*, 2016. (Cited on page 6.)
- [Mnih 2015] Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir

- Sadik, Ioannis Antonoglou, Helen King, Dharshan Kumaran, Daan Wierstra, Shane Legg and Demis Hassabis. *Human-level control through deep reinforcement learning*. Nature, vol. 518, no. 7540, pages 529–533, 2015. (Cited on pages 6 and 7.)
- [Morstyn 2018] Thomas Morstyn, Branislav Hredzak and Vassilios G. Agelidis. *Control Strategies for Microgrids with Distributed Energy Storage Systems: An Overview*. IEEE Transactions on Smart Grid, vol. 9, no. 4, pages 3652–3666, 2018. (Cited on page 5.)
- [Nakabi 2021] Timothy Aduda Nakabi and Pekka Toivanen. *Deep reinforcement learning for energy management in a microgrid with flexible demand*. Sustainable Energy, Grids and Networks, vol. 25, page 100413, 2021. (Cited on page 7.)
- [Oldewurtel 2012] Frauke Oldewurtel, Alessandra Parisio, Colin N. Jones, Dimitrios Gyalistras, Markus Gwerder, Vanessa Stauch, Beat Lehmann and Manfred Morari. *Use of model predictive control and weather forecasts for energy efficient building climate control*. Energy and Buildings, vol. 45, pages 15–27, 2012. (Cited on page 5.)
- [Parra 2017] David Parra, Maciej Swierczynski, Daniel I. Stroe, Sarah A. Norman, Alfred Abdon, Jörg Worlitschek, Tim O’Doherty, Luis Rodrigues, Mark Gillott, Xiang Zhang, Christian Bauer and Martin K. Patel. *An interdisciplinary review of energy storage for communities: challenges and perspectives*. Renewable and Sustainable Energy Reviews, vol. 79, pages 730–749, 2017. (Cited on page 5.)
- [Perera 2021] A. T. D. Perera and Parameswaran Kamalaruban. *Applications of reinforcement learning in energy systems*. Renewable and Sustainable Energy Reviews, vol. 137, page 110618, 2021. (Cited on page 6.)
- [Raffin 2021] Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus and Noah Dormann. *Stable-Baselines3: Reliable Reinforcement Learning Implementations*. Journal of Machine Learning Research, vol. 22, no. 268, pages 1–8, 2021. (Cited on page 8.)
- [Schulman 2017] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford and Oleg Klimov. *Proximal Policy Optimization Algorithms*. arXiv preprint, vol. arXiv:1707.06347, 2017. (Cited on pages 7 and 16.)
- [Sutton 2018] Richard S. Sutton and Andrew G. Barto. *Reinforcement learning: An introduction*. MIT Press, Cambridge, MA, 2nd edition, 2018. (Cited on pages 7 and 14.)

- [Towers 2024] Mark Towers, Jordan K. Terry, Ariel Kwiatkowski, John U. Balis, Gianluca de Cola, Tristan Deleu, Manuel Goulão, Andreas Kallinteris, Markus Krimmel, Arjun KG, Rodrigo Perez Santos, Gil Serrano, Rodrigo Sousa, Jakub Szczudlik, Jinming Wang and Omar G. Younis. *Gymnasium: A Standard Interface for Reinforcement Learning Environments*. arXiv preprint, vol. arXiv:2407.17032, 2024. (Cited on page 9.)
- [Vazquez-Canteli 2019] Jose R. Vazquez-Canteli and Zoltan Nagy. *Reinforcement learning for demand response: A review of algorithms and modeling techniques*. Applied Energy, vol. 235, pages 1072–1089, 2019. (Cited on page 6.)