

Treball Final de Màster

Estudi: Màster en Ciència de Dades

Títol: Control híbrid basat en Aprenentatge per Reforç i Control Predictiu per a l'optimització segura de sistemes d'emmagatzematge amb bateries

Document: Resum

Alumne: David Bruguera Tornés

Tutor: Andrés El-Fakdi Sencianes
Departament: Enginyeria Elèctrica, Electrònica i Automàtica
Àrea: Enginyeria Elèctrica

Convocatòria (mes/any): Juny 2026

Introducció i context

La creixent penetració de fonts d'energia renovable distribuïdes introdueix una elevada volatilitat en la generació i en els preus de l'electricitat. En aquest escenari, els sistemes d'emmagatzematge d'energia en bateria (*Battery Energy Storage Systems*, BESS) són elements crítics per aportar flexibilitat i estabilitat. La gestió òptima d'un BESS és complexa per dos motius principals: la incertesa estocàstica en generació, demanda i preus futurs, i la necessitat de complir estrictes restriccions físiques (estat de càrrega, potència màxima d'inversor) per garantir la seguretat i la vida útil dels equips.

Els mètodes clàssics de Control Predictiu basat en Model (MPC) gestionen bé les restriccions, però depenen de la precisió del model del sistema i de les previsions. L'Aprenentatge per Reforç (RL) s'adapta millor a entorns estocàstics sense necessitar un model explícit, però en la seva forma estàndard no garanteix inherentment el compliment de restriccions físiques. **Aquest TFM proposa una arquitectura de control híbrida** que integra ambdós enfocaments per obtenir el millor de cadascun: l'adaptabilitat del RL i les garanties de seguretat del MPC.

El cas d'estudi és una comunitat energètica a Cornellà de Llobregat (Barcelona), composta per 20 habitatges amb una instal·lació fotovoltaica compartida de 15 kW i un BESS de 50 kWh amb inversor de 50 kW.

Objectius

L'objectiu principal és dissenyar, implementar i validar una estratègia de control híbrida que integri un agent d'Aprenentatge per Reforç amb un *tracker* MPC per operar el BESS de forma segura i econòmicament eficient.

Els objectius específics són:

1. Desenvolupar un entorn de simulació (Gymnasium) integrat amb el simulador de la comunitat energètica, incloent un model de bateria simplificat i perfils de mercat elèctric.
2. Implementar un agent PPO (*Proximal Policy Optimization*) que aprengui polítiques de càrrega/descàrrega per maximitzar el benefici econòmic.
3. Integrar un *tracker* MPC que segueixi un SoC objectiu proposat per l'agent RL, garantint el compliment de les restriccions físiques de la bateria.
4. Comparar el rendiment de l'arquitectura híbrida (MPC+RL) respecte a tres estratègies de referència: MPC greedy d'un sol pas MPC(H=1), MPC amb horitzó de 60 minuts MPC(H=60) i l'agent RL en solitari.

Procés de desenvolupament

El desenvolupament s'ha estructurat en quatre fases principals:

1. Entorn de simulació. S'ha implementat l'entorn BessEnv seguint la interfície Gymnasium, integrat amb el simulador de la comunitat energètica desenvolupat per Martí Cabarrocas I Sánchez en el seu Treball de Fi de Grau. El vector d'observació conté 8 variables normalitzades: estat de càrrega de la bateria, generació solar, demanda agregada, preu de l'electricitat i codificació cíclica del temps (sin/cos). El simulador genera 7.300 dies de dades (conjunt d'entrenament: 5.840 dies; conjunt de test: 1.460 dies).

2. Controlador MPC. S'ha implementat un controlador MPC basat en CVXPY amb el solver CLARABEL en dues variants: greedy d'un sol pas MPC(H=1) i amb horitzó de 60 minuts MPC(H=60). El MPC opera amb informació perfecta del pas actual i, dins l'arquitectura híbrida, s'utilitza com a *tracker* per seguir referències de SoC.

3. Entrenament de l'agent PPO. L'agent s'ha entrenat durant 2.000.000 de passos sobre el conjunt d'entrenament. Un repte clau del disseny ha estat l'ajust de la funció de recompensa: amb una penalització de degradació massa elevada, l'agent aprenia la política d'inacció (no moure mai la bateria). S'ha calibrat un multiplicador de degradació $\text{DEG_PENALTY_MULT} = 8.0$ que equilibra el benefici econòmic i la protecció de la bateria.

4. Arquitectura híbrida MPC+RL. L'agent RL proposa un SoC objectiu cada 60 minuts. El *tracker* MPC resol un problema d'optimització en horitzó de 60 minuts i calcula les accions minut a minut per seguir aquesta referència respectant límits de SoC i potència. Aquesta arquitectura combina adaptabilitat (RL) i seguretat operativa (MPC).

5. Estudi d'ablació. Per validar les decisions de disseny de la xarxa neuronal de l'agent MPC+RL, s'ha realitzat un estudi d'ablació sistemàtic amb 8 configuracions: 4 funcions d'activació (ReLU, Leaky ReLU, ELU, Tanh) $\times$ 2 valors de $\text{GAE-}\lambda$ (0.95 i 1.00), cadascuna entrenada durant 500.000 timesteps. Les conclusions principals confirmen que la configuració original (ReLU, $\lambda = 0,95$) és pràcticament òptima i que totes les configuracions convergeixen a valors similars (rang $< 7\%$), evidenciant que la *tracker* MPC fa el sistema robust als hiperparàmetres de la xarxa neuronal.

Resultats

L'avaluació comparativa sobre 1.460 dies de test (2.102.400 minuts de simulació) proporciona els resultats de la Taula 1.

Quatre troballes destacades:

Mètrica	MPC(H=1)	MPC(H=60)	RL	MPC+RL
Benefici net (€)	-97.826	-97.502	-94.035	-87.142
Estalvi vs MPC(H=1) (€)	0	+324	+3.792	+10.684
Estalvi vs MPC(H=1) (%)	0%	+0,3%	+3,9%	+10,9%
Cicles complets	0,0	247,3	891,7	1.950,5
SoC mitjà	0,000	0,010	0,230	0,705
% temps inactiu	100%	92,4%	58,9%	72,5%
Temps decisió (ms)	0,63	3,77	0,13	2,06

Taula 1: Comparativa dels quatre controladors sobre 1.460 dies de test.

1. **MPC(H=1) és completament inactiu.** El controlador greedy no pot anticipar períodes favorables sense horitzó de predicció i opta sistemàticament per la inacció (100% del temps), constituint la cota inferior del sistema.
2. **L'agent RL supera el MPC(H=60) en 3.468 €.** Malgrat no tenir accés explícit a previsions de generació i demanda, l'agent aprèn una política de ciclatge temporalment coherent i quasi-perfectament simètrica (44.583,0 vs 44.580,6 kWh en 1.460 dies).
3. **MPC+RL és el millor en totes les mètriques econòmiques.** Redueix la pèrdua en 10.684 € (10,9%) respecte al MPC(H=1) i en 6.892 € respecte al RL en solitari, equivalent a **7,32 €/dia d'estalvi**. El *tracker* MPC garanteix la simetria exacta de la càrrega/descàrrega (97.526,5 kWh en ambdues direccions) i un SoC mitjà alt (0,705).
4. **Temps de decisió compatibles amb temps real.** Tots quatre controladors operen en menys d'1 minut per pas de decisió (RL: 0,13 ms; MPC+RL: 2,06 ms).

Conclusions

Aquest TFM ha demostrat que una arquitectura híbrida *RL-guided MPC* és viable i eficient per al control segur i econòmicament rendible d'un BESS en una comunitat energètica. Les contribucions principals han estat: (1) el disseny i la implementació de l'entorn de simulació *BessEnv* integrat amb el simulador de la comunitat; (2) l'ajust rigorós de la funció de recompensa per evitar la política d'inacció; i (3) la validació que el *tracker* MPC garanteix la seguretat operativa mentre segueix les referències de SoC proposades per l'agent.

Les línies de treball futur més prometedores inclouen: l'ús de dades de mercat reals en línia per complementar els CSVs del simulador; un model de degradació no lineal (dependent de la profunditat de descàrrega i de la temperatura); i l'exploració d'algoritmes alternatius com SAC o TD3 dins del mateix esquema *RL-guided MPC*.