

Control híbrid MPC + RL per a sistemes d'emmagatzematge en comunitats energètiques

Resum tècnic

David Bruguera Tornés — Tutor: Andrés El-Fakdi Sencianes
Màster en Ciència de Dades — Juny 2026

Cas d'estudi. Comunitat energètica a Cornellà de Llobregat: 20 habitatges i una escola amb una instal·lació fotovoltaica compartida de 15 kW de pic i un BESS (*Battery Energy Storage System*) de 50 kWh / 50 kW d'inversor. El simulador de la comunitat genera 7.300 dies de dades de generació solar, demanda agregada i preus PVPC; es divideixen en 80 % d'entrenament (5.840 dies) i 20 % de test (1.460 dies).

Notació.

Símbol	Significat
t, τ	instants de temps; $\Delta t = 1 \text{ min} = 1/60 \text{ h}$
P_t^{batt}	potència bateria (kW); positiu = càrrega, negatiu = descàrrega
P_{max}	potència màxima de l'inversor (50 kW)
SoC_t	estat de càrrega $[0, 1]$; capacitat $C_{\text{bat}} = 50 \text{ kWh}$
η	eficiència de la bateria ($\eta = 1$ en la implementació)
E_t^+, E_t^-	energia comprada / venuda a la xarxa (kWh, ≥ 0)
p_t^+, p_t^-	preu de compra / venda de l'electricitat (€/kWh)
D_t, G_t	demanda total i generació solar (kW)
c_{deg}	cost de degradació de la bateria (0,010 €/kWh)
π_θ, s_t, a_t	<i>policy</i> RL, vector d'estat ($\mathbb{R}^8$) i acció
$r_t, \gamma, \hat{A}_t$	recompensa, factor de descompte i avantatge estimat (GAE)
SoC_{ref}	SoC objectiu proposat per l'agent RL (MPC+RL)
$w = 20$	pes de la penalització de seguiment del SoC (MPCTracker)

1. Model de la bateria

L'estat de càrrega (*State of Charge*, SoC) evoluciona a cada pas de $\Delta t = 1/60 \text{ h}$ (1 minut) segons:

$$\text{SoC}_{t+1} = \text{SoC}_t + \frac{\eta \cdot P_t^{\text{batt}} \cdot \Delta t}{C_{\text{bat}}}, \quad \eta = 1 \quad (1)$$

amb $C_{\text{bat}} = 50 \text{ kWh}$ i les restriccions físiques $P_t^{\text{batt}} \in [-50, 50] \text{ kW}$ i $\text{SoC}_t \in [0, 1]$. L'eficiència unitària ($\eta = 1$) simplifica la dinàmica; addicionalment, el cost de degradació es dobla si el SoC opera fora del rang $[0,10, 0,90]$ per penalitzar l'ús als extrems.

2. Controladors

MPC($H = 1$) — greedy d'un sol pas

En cada minut t , resol el problema d'optimització convexa ($H = 1$):

$$\max_{\{P_\tau, E_\tau^+, E_\tau^-\}} \sum_{\tau=t}^{t+H-1} \left[(p_\tau^- \cdot E_\tau^-) - (p_\tau^+ \cdot E_\tau^+) - (c_{\text{deg}} \cdot |P_\tau| \cdot \Delta t) \right] \quad (2)$$

$$\begin{aligned} \text{subjecte a } E_\tau^+ - E_\tau^- &= (D_\tau - G_\tau + P_\tau) \cdot \Delta t \quad (E_\tau^+, E_\tau^- \geq 0) \\ -P_{\max} &\leq P_\tau \leq P_{\max}, \quad \text{SoC}_{\min} \leq \text{SoC}_{\tau+1} \leq \text{SoC}_{\max} \end{aligned}$$

S'optimitzen conjuntament la potència de la bateria (P_τ) i els fluxos d'energia amb la xarxa (E_τ^+ , E_τ^-): es maximitza el que es ven ($p^- \cdot E^-$, ingressos) menys el que es compra ($p^+ \cdot E^+$, cost) i la penalització de degradació per ciclatge. La restricció de balanç assegura que el flux net amb la xarxa cobreix exactament la demanda neta de la comunitat ($D_\tau - G_\tau$) més la potència de la bateria; les restriccions de SoC i potència garanteixen l'operació física segura. Implementat amb CVXPY i el *solver* CLARABEL. Sense horitzó, no pot anticipar períodes favorables: com que el preu de venda (0,080 €/kWh) és inferior al de compra (0,120 €/kWh), el MPC($H = 1$) opta sistemàticament per la **inacció** (100 % del temps), constituint la cota inferior del sistema.

MPC($H = 60$) — horitzó de 60 minuts

Estén el mateix problema a $H = 60$ passos amb coneixement perfecte dels preus, generació i demanda futurs, resolent un sol LP (*Linear Program*) per iteració:

$$\max_{\{P_\tau, E_\tau^+, E_\tau^-\}} \sum_{\tau=t}^{t+H-1} \left[(p_\tau^- \cdot E_\tau^-) - (p_\tau^+ \cdot E_\tau^+) - (c_{\text{deg}} \cdot |P_\tau| \cdot \Delta t) \right] \quad (3)$$

$$\begin{aligned} \text{subjecte a } E_\tau^+ - E_\tau^- &= (D_\tau - G_\tau + P_\tau) \cdot \Delta t, \quad E_\tau^+, E_\tau^- \geq 0 \\ -P_{\max} &\leq P_\tau \leq P_{\max}, \quad \text{SoC}_{\min} \leq \text{SoC}_\tau \leq \text{SoC}_{\max} \end{aligned}$$

L'estructura és idèntica al MPC($H = 1$) però l'horitzó de 60 passos permet anticipar variacions de preus o generació i planificar càrregues/descàrregues en moments econòmicament favorables. Actua el 7,6 % del temps i millora el MPC($H = 1$) en 324 € en 1.460 dies (0,22 €/dia), benefici marginal molt petit.

Agent RL — PPO (*Proximal Policy Optimization*)

Policy function i xarxa neuronal. L'agent modela una *policy* $\pi_\theta(a_t | s_t)$ parametritzada per una xarxa neuronal MLP (*Multi-Layer Perceptron*) amb funció d'activació ReLU (*Rectified Linear Unit*). La transició entre estats segons aquesta *policy* es defineix com:

$$s_t \in \mathbb{R}^8 \xrightarrow{a_t \in [-1,1]} s_{t+1} \in \mathbb{R}^8 \quad (4)$$

El vector d'estat s_t conté 8 variables normalitzades: SoC, generació solar, demanda escola, demanda habitatges, preu de l'electricitat i codificació cíclica del temps ($\sin \theta_t$, $\cos \theta_t$, hora normalitzada). L'acció $a_t = 1$ correspon a càrrega màxima i $a_t = -1$ a descàrrega màxima.

L'arquitectura **actor-crític** (*actor-critic*) separa la representació en dues xarxes independents: l'**actor** aprèn la *policy* $\pi_\theta(a_t | s_t)$ (quina acció executar donat l'estat), i el **crític** estima el valor esperat de cada estat $V(s_t)$ per calcular l'avantatge i guiar el gradient de l'actor sense modificar-ne la *policy* directament. Actor: **1 capa de 64 neurones**; crític: **2 capes de 64 neurones**.

Reward function. La recompensa principal és el **guany marginal respecte a no usar la bateria**, menys la penalització de degradació:

$$r_t = \underbrace{(b_t^{\text{batt}} - b_t^{\text{ref}})}_{\text{guany marginal}} - \underbrace{\alpha_{\text{deg}} \cdot c_{\text{deg}} \cdot |P_t^{\text{batt}}| \cdot \Delta t}_{\text{cost degradació}}, \quad c_{\text{deg}} = 0,010 \text{ €/kWh} \quad (5)$$

on b_t^{batt} és el benefici econòmic net amb bateria, b_t^{ref} el benefici sense bateria i α_{deg} és un factor calibrat experimentalment per evitar la *policy* d'inacció.

Retorn descomptat i objectiu de PPO. L'agent maximitza el retorn esperat descomptat:

$$J(\theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{t=0}^T \gamma^t r_{t+1} \right], \quad \gamma = 0,999 \quad (6)$$

PPO estima el gradient via l'avantatge generalitzat (GAE, *Generalized Advantage Estimation*, $\lambda = 0,98$) i aplica una restricció de *clip* per garantir actualitzacions estables:

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 \pm \epsilon) \hat{A}_t \right) \right], \quad \epsilon = 0,2 \quad (7)$$

on $r_t(\theta) = \pi_\theta(a_t|s_t)/\pi_{\theta_{\text{old}}}(a_t|s_t)$ és el ràtio de probabilitats i $\hat{A}_t$ l'avantatge estimat. Entrenament: **2.000.000 timesteps** sobre 5.840 dies d'entrenament.

3. Arquitectura híbrida MPC + RL

La idea central és combinar l'adaptabilitat de l'agent RL amb la capacitat d'optimització multi-pas del MPC. L'arquitectura té dos nivells temporals: un **macro-pas** (decisió de l'RL, cada 60 minuts) i un **micro-pas** (execució del MPC, cada minut).

Macro-pas — decisió de l'RL (cada 60 minuts). L'agent RL observa l'estat s_t i proposa un **SoC objectiu**:

$$\text{SoC}_{\text{ref}} = \pi_\theta(s_t) \in [0, 1] \quad (8)$$

que la bateria hauria d'assolir en els pròxims 60 minuts. Per a aquest agent, l'arquitectura és [64,64] per a l'actor i el crític ($\gamma = 0,994$, $\lambda = 0,95$), i la recompensa és el guany marginal respecte a l'escenari sense bateria (eq. (5)).

Micro-pas — execució del MPC (cada minut). Un **MPCTracker** amb horitzó $H = 60$ (CVXPY/CLARABEL) resol en cada minut un problema de programació quadràtica que minimitza el cost econòmic de transaccions més una penalització per desviació respecte al SoC objectiu:

$$\min_{\{P_\tau, E_\tau^+, E_\tau^-\}} \sum_{\tau=t}^{t+H-1} \left[p_\tau^+ \cdot E_\tau^+ - p_\tau^- \cdot E_\tau^- \right] + w \cdot (\text{SoC}_{t+H_{\text{rem}}} - \text{SoC}_{\text{ref}})^2 \quad (9)$$

$$\begin{aligned} \text{subjecte a } & E_\tau^+ - E_\tau^- = (D_\tau - G_\tau + P_\tau) \cdot \Delta t, \quad E_\tau^+, E_\tau^- \geq 0 \\ & -P_{\text{max}} \leq P_\tau \leq P_{\text{max}}, \quad \text{SoC}_{\text{min}} \leq \text{SoC}_\tau \leq \text{SoC}_{\text{max}} \end{aligned}$$

Es minimitza el cost net de transaccions amb la xarxa (comprar menys vendre), penalitzant la desviació del SoC respecte al SoC objectiu proposat per l'agent. La penalització $w(\cdot)^2$ s'aplica únicament al pas final del macro-pas ($t + H_{\text{rem}}$), no a tots els passos de l'horitzó. L'acció executada és $P_t^* = P_\tau[0]$ (primer pas de la seqüència òptima), i un filtre de seguretat garanteix els límits de SoC i potència.

L'arquitectura garanteix **zero violacions de restriccions** sense necessitat de reentrenar l'agent, i produeix els millors resultats econòmics de tots els controladors avaluats.

4. Resultats (1.460 dies de test)

Controlador	Benefici net (€)	Estalvi vs MPC($H=1$)	Cicles bat.	SoC mitjà
MPC($H = 1$)	-97.826	—	0	0,000
MPC($H = 60$)	-97.502	+324 € (+0,3 %)	247	0,010
RL (PPO)	-94.035	+3.792 € (+3,9 %)	892	0,230
MPC+RL	-87.142	+10.684 € (+10,9 %)	1.951	0,705

Avaluació sobre 2.102.400 minuts de simulació. Temps de decisió: MPC($H = 1$) 0,63 ms; MPC($H = 60$) 3,77 ms; RL 0,13 ms; MPC+RL 2,06 ms — tots compatibles amb temps real.

Conclusions principals:

- **MPC+RL** és el millor en totes les mètriques econòmiques: estalvi de **7,32 €/dia** respecte a la inacció total del MPC($H = 1$), i **4,72 €/dia** addicionals sobre el RL en solitari.
- L'**agent RL** supera el MPC($H = 60$) en 3.468 € sense tenir accés explícit a previsions de generació ni demanda; la seva *policy* de ciclatge és quasi-perfectament simètrica (44.583 vs 44.581 kWh en 1.460 dies).
- La **capa de projecció** garanteix simetria exacta de càrrega/descàrrega (97.527 kWh en cada sentit) i zero violacions de restriccions; la seguretat operativa no requereix reentrenar l'agent.
- L'**estudi d'ablació** (4 activacions $\times$ 2 valors de GAE- λ , cadascuna 500k timesteps) confirma que el sistema és robust als hiperparàmetres: rang de variació $< 7\%$ entre totes les configuracions, gràcies a la simplificació que la capa de projecció imposa sobre la tasca de l'agent.